

LABORATÓRIO 5 — Bronze: limpeza e padronização

Bronze - Clientes

```
CREATE TABLE bronze_customers
STORED AS PARQUET AS
SELECT DISTINCT
  customer_id, name, cpf, email, segment,
  CAST(credit_score AS INT) AS credit_score,
  CAST(created_at AS DATE) AS created_at
FROM raw_customers
WHERE customer_id IS NOT NULL
  AND credit_score BETWEEN 300 AND 900;

SELECT COUNT(*) FROM raw_customers;
SELECT COUNT(*) FROM bronze_customers;
```

```
raw_customers:    9993
bronze_customers: 9993
```

Os 9.993 clientes passaram pelas regras de limpeza e validação definidas para a camada Bronze. Nesse conjunto, nenhum registro foi eliminado pelos filtros utilizados.

Bronze - transações

```
CREATE TABLE bronze_transactions
STORED AS PARQUET AS
SELECT DISTINCT
  transaction_id, customer_id,
  CAST(amount AS FLOAT) AS amount,
  transaction_type, status,
  CAST(risk_score AS FLOAT) AS risk_score,
  CAST(is_fraud AS BOOLEAN) AS is_fraud,
  CAST(ts AS TIMESTAMP) AS ts
FROM raw_transactions
WHERE amount > 0
  AND customer_id IS NOT NULL;
```

```
Tabela bronze_transactions criada com sucesso em formato Parquet.
```

As transações foram padronizadas e gravadas em Parquet, com conversão de tipos e aplicação dos filtros de valores maiores que zero e cliente “não ser NULL”, ou seja, cliente identificado.

```
SELECT MIN(amount), MAX(amount), COUNT(*) FROM bronze_transactions;  
SELECT is_fraud, COUNT(*) FROM bronze_transactions GROUP BY is_fraud;
```

```
SELECT transaction_id, COUNT(*) c  
FROM bronze_transactions  
GROUP BY transaction_id  
HAVING c > 1;
```

MIN(amount)	MAX(amount)	COUNT(*)
10.0	22927.023	100000

is_fraud	quantidade
false	98167
true	1833

Duplicidades de transaction_id:
0 linhas

A camada Bronze manteve 100.000 transações válidas, com valores entre 10,00 e 22.927,023. Foram identificadas 1.833 fraudes e 98.167 transações não fraudulentas. A consulta de duplicidades não retornou nenhuma linha em duplicidade.