

LABORATÓRIO 12 — ML Preview: modelo simples de fraude

```
df = spark.read.parquet("hdfs://localhost:9000/user/hive/warehouse/silver_transactions")

from pyspark.ml.feature import StringIndexer, VectorAssembler
from pyspark.ml.classification import LogisticRegression
from pyspark.ml import Pipeline

indexer = StringIndexer(inputCol="segment", outputCol="segment_idx")
assembler = VectorAssembler(
    inputCols=["amount", "risk_score", "credit_score", "segment_idx"],
    outputCol="features"
)

df_ml = df.withColumn("label", df.is_fraud.cast("integer"))
train, test = df_ml.randomSplit([0.8, 0.2], seed=42)
print("treino:", train.count(), "· teste:", test.count())

treino: 79901 · teste: 20099
```

Os dados foram preparados para machine learning, transformando o segmento em variável numérica, com 80% das observações para treino e 20% para teste.

Treinamento

```
lr = LogisticRegression(featuresCol="features", labelCol="label")
pipeline = Pipeline(stages=[indexer, assembler, lr])
modelo = pipeline.fit(train)
print("Modelo treinado.")

Modelo treinado.
```

Foi treinado um classificador de Regressão Logística

Avaliação do modelo

```
from pyspark.ml.evaluation import BinaryClassificationEvaluator

predicoes = modelo.transform(test)
avaliador = BinaryClassificationEvaluator(labelCol="label")
auc = avaliador.evaluate(predicoes)
print(f"AUC no teste: {auc:.3f}")

AUC no teste: 0.768
```

A AUC de 0,768 indica que o modelo conseguiu uma boa generalização.

Exemplos de predição

```
predicoes.select(
    "transaction_id", "amount", "segment", "label", "prediction", "probability"
).show(10, truncate=False)
```

transaction_id	amount	segment	label	prediction	probability [não fraude, fraude]
3	93.935265	High-Risk	0	0.0	[0.949578, 0.050422]
7	140.57378	Premium	0	0.0	[0.994479, 0.005521]
9	10.0	High-Risk	0	0.0	[0.933876, 0.066124]
14	81.39329	Standard	0	0.0	[0.975478, 0.024522]
20	34.814598	Premium	0	0.0	[0.995005, 0.004995]
24	26.91095	Premium	0	0.0	[0.988865, 0.011135]
30	130.24501	Standard	0	0.0	[0.986781, 0.013219]
36	89.36897	Standard	0	0.0	[0.956971, 0.043029]
46	80.55228	Standard	0	0.0	[0.963180, 0.036820]
47	54.159405	Premium	0	0.0	[0.996904, 0.003096]

Nas dez primeiras observações exibidas, o modelo classificou os registros como não fraudulentos e apresentou a probabilidade estimada para cada classe.

Coeficientes da Regressão Logística

```
lr_model = modelo.stages[-1]
coefs = lr_model.coefficients
nomes = ["amount", "risk_score", "credit_score", "segment_idx"]
```

```
for nome, coef in zip(nomes, coefs):
    print(f"{nome}: {coef:.4f}")
```

```
amount:      -0.0002
risk_score:   0.0167
credit_score: 0.0001
segment_idx:  1.1849
```

Entre os coeficientes obtidos, segmento apresentou a maior magnitude positiva, seguido de risk_score.